



Machine Learning 2026 | Semana 2

Tipos de Aprendizaje Automático: Supervisado, No Supervisado y por Refuerzo



Propósito de la Sesión

¿Qué seremos capaces de hacer al finalizar esta clase?



Diferenciar paradigmas: **Supervisado**, **No supervisado** y **Por refuerzo** según la disponibilidad de datos y el objetivo.




Comprender la mecánica: El rol de las etiquetas y variables en clasificación, regresión y clustering.



Modelar agentes: Definir conceptos de agente, entorno y recompensa en el aprendizaje por refuerzo.



Aplicar al mundo real: Asociar problemas reales con el tipo de algoritmo adecuado.



Conectar con el proyecto: Identificar nuestro proyecto de clasificación de imágenes dentro del mapa de Machine Learning.

¿De qué maneras puede aprender una máquina?

Tres lógicas distintas basadas en la disponibilidad de datos y el objetivo

Datos + Respuestas conocidas

Aprendizaje Supervisado

Lógica: Enseñar con ejemplos. El modelo cuenta con una referencia clara para corregirse.

Datos + Respuestas NO conocidas

Aprendizaje No Supervisado

Lógica: Descubrir estructuras. El modelo agrupa o encuentra patrones ocultos por sí mismo.

Agente + Entorno + Recompensas

Aprendizaje Por Refuerzo

Lógica: Aprender interactuando. El modelo mejora su estrategia mediante acierto y error.

Aprendizaje Supervisado: Enseñar con ejemplos

Utiliza un Dataset con la respuesta correcta esperada (Etiqueta)

1. Fase de Entrenamiento (Training)

Entrada X
(Imagen de Gato)

[.....]
[.....]
[.....]

Etiqueta Y
("Gato")
[("Gato")]



2. Fase de Predicción (Inferencia)

Nueva Entrada X
(Foto nunca vista)




Predicción $\hat{Y}$
 $\hat{Y}$ ("Gato")
✓

Se denomina "**Supervisado**" porque la etiqueta conocida funciona como un supervisor que corrige al modelo durante su aprendizaje.


Anatomía de los Datos en el Aprendizaje Supervisado

Diferenciando la información provista del resultado esperado





Problemas Supervisados: Clasificación vs. Regresión

La diferencia radica en la naturaleza de la salida (el Target)



Predice una **CATEGORÍA** (Clases).

 **Binaria** (2 clases): Spam / No Spam;
 Fraude / Legítimo.

 **Multiclase** (>2 clases): Notebook / Smartphone / Tablet / Monitor; o Plástico / Vidrio / Cartón / Metal.



Predice un **VALOR NUMÉRICO CONTINUO**.

Ejemplos:

-  Características de vivienda → Precio estimado.
-  Información histórica → Ventas esperadas.
-  Variables meteorológicas → Temperatura estimada.

• Aprendizaje No Supervisado: Descubriendo Patrones

Datos de entrada sin un resultado esperado conocido



El Reto:

No disponemos de etiquetas.
El algoritmo no tiene un
objetivo a imitar.

El Objetivo:

Descubrir agrupaciones o
relaciones ocultas por
sí mismo.

Caso de Uso: Clustering de Clientes

- **Input:** Frecuencia de compra, gasto, visitas (Sin segmentos definidos).
- **Output:** El algoritmo descubre perfiles (Ej: Grupo 1 "Frecuentes" / Grupo 2 "Ocasionales").
- **Nota:** Estas categorías NO existían antes en el Dataset.

La Distinción Crítica: Clasificación vs. Clustering

Categorías predefinidas frente a descubrimiento de grupos

 Clasificación (Supervisado) 	 Clustering (No Supervisado) 
Punto de partida Las clases ya existen y se conocen previamente.	Los grupos no están definidos previamente.
Proceso de aprendizaje Entrenamos con ejemplos ya etiquetados (Imagen 1 → Perro).	El algoritmo agrupa analizando similitudes en los datos.
Objetivo final Asignar nuevas observaciones a clases que ya conocemos.	Descubrir agrupaciones que no sabíamos que existían.

Otros Casos de Uso del Aprendizaje No Supervisado


Más allá del **Clustering**: descubriendo y simplificando



Reducción de Dimensionalidad:
Sintetiza información compleja en menos variables conservando los datos relevantes.



Exploración de Datos:
Permite comprender grandes volúmenes de información antes de construir modelos predictivos.



Identificación de Estructuras:
Descubre relaciones o patrones (ej. reglas de asociación entre productos).



Detección de Anomalías: Identifica observaciones que se desvían drásticamente del comportamiento habitual (comportamientos poco frecuentes).

• Aprendizaje Por Refuerzo: Decisiones Iterativas

Un agente que interactúa, recibe feedback y aprende de su entorno



El Ciclo:

Agente observa Estado → Ejecuta Acción → Entorno responde → Agente recibe Recompensa y nuevo Estado → Actualiza estrategia.

Ejemplo: Robot en un laberinto

Acciones: Avanzar, retroceder, girar.

Recompensas: Llegar a meta (+100) | Chocar obstáculo (-10) | Moverse (-1).

Objetivo: Maximizar la recompensa acumulada aprendiendo una estrategia secuencial óptima. (Aplicaciones: Videojuegos, robótica, navegación autónoma).


● Matriz de los Tres Paradigmas

Comparativa fundamental de arquitecturas de aprendizaje

Paradigma	Supervisado	No Supervisado	Por Refuerzo
Datos Etiquetados	Sí	No necesariamente	No opera por datasets etiquetados
Referencia	Resultado esperado conocido	No existe necesariamente	Señal de recompensa iterativa
Objetivo	Predecir resultados	Descubrir patrones	Aprender estrategia de decisión
Vía de Aprendizaje	Mediante ejemplos	Mediante estructuras	Mediante interacción
Casos Típicos	Clasificación, Regresión	Clustering	Control, Decisiones secuenciales

Árbol Lógico: ¿Qué paradigma utilizar?

Diagnóstico del problema basado en la información disponible



El Proyecto Integrador en el Mapa de ML


¿Dónde se ubica nuestra solución de clasificación de imágenes?

Parámetros del Proyecto:

Entrada (Features):
Imágenes

Resultados conocidos (Target):
Clases (Plástico, Vidrio,
Cartón, Metal)

Objetivo:
Clasificar imágenes nuevas



Casos de Discusión en Clase

Identifica el paradigma correcto para cada situación

Caso 1:

Clasificar nuevas **transacciones** financieras basado en miles de **históricos** etiquetados como fraude o legítimo.



Caso 2:

Agrupar **100.000 clientes** para descubrir diferentes perfiles de consumidores sin categorías previas.



Caso 3:

Robot esquivando obstáculos para llegar a una meta, recibiendo premios por éxito.



Caso 4:

Reconocer 5 especies de flores utilizando un dataset de fotos pre-etiquetadas.



Caso 5:

Estimar el precio numérico de propiedades nuevas basado en características e históricos de ventas.



Síntesis y Próximos Pasos

Lo que hemos mapeado hoy y hacia dónde vamos en la Semana 3

Síntesis de la Semana 2

- ✓ La elección del paradigma depende exclusivamente de los datos disponibles y el objetivo.
- ✓ **Supervisado:** Usa etiquetas conocidas para predecir (Clasificación vs. Regresión).
- ✓ **No supervisado:** Descubre agrupaciones sin respuestas previas (Clustering).
- ✓ **Por refuerzo:** Aprende estrategias óptimas interactuando iterativamente con un entorno.
- ✓ Nuestro proyecto integrador es un modelo Supervisado de Clasificación Multiclase.

Hacia la Semana 3



¿Cómo se construye y entrena una solución de aprendizaje supervisado?

Profundizaremos en el flujo técnico completo:
Datos → Features → Etiquetas → Training → Predicción.