






Aprendizaje Supervisado y Entrenamiento


Del procesamiento de datos a la inferencia de modelos




Propósito de la Sesión




Identificar componentes de una solución supervisada.




Diferenciar Features (características) y Etiquetas (Labels).



Comprender el ciclo de Training y ajuste de parámetros.



Contrastar operaciones: Training vs. Inferencia.




Conectar el flujo genérico con el Proyecto Integrador (Clasificación CNN).

ITERATIVE PROCESS

El Paradigma del Aprendizaje Supervisado

La regla de oro:
Datos de entrada +
Resultado conocido.



El objetivo es construir una estructura matemática capaz de generalizar sobre datos no vistos.

X (Features)				y (Label)
	Superficie	Dormitorios	Antigüedad	Precio
1	60m ²	2 dorm	15 años	\$75M
2	120m ²	4 dorm	3 años	\$160M

- X


(Features / Características):
Variables de entrada. La información que el modelo utiliza para encontrar patrones.
- y

(Etiqueta / Variable Objetivo):
El resultado esperado o correcto asociado a X.
- $\hat{y}$

(Predicción):
El resultado final generado por el modelo.

Fórmula conceptual:

$$X \rightarrow \text{Modelo} \rightarrow \hat{y}$$



⇒ Para el computador, una imagen no es un objeto, es una estructura matricial de valores numéricos.


⇒ Cada píxel indica **intensidad o color**.
Escala de grises: 1 matriz 2D.

⇒ **Color: 3 canales RGB** (matrices apiladas).


Las **Redes Neuronales Convolucionales** (CNN) del proyecto aprenderán patrones visuales directamente a partir de estos números.

El Dataset y la Separación de Datos

Datos de Training



Master Dataset




80%

20%

Master Dataset

Datos de Test



Dataset de Entrenamiento:

Pares de observaciones ($X + y$) utilizados repetidamente para ajustar el modelo.




La trampa de la memorización:

Si evaluamos con las mismas preguntas que usamos para enseñar, no medimos el aprendizaje real (riesgo de Overfitting).

Solución (Dataset de Test):


Separar un conjunto de datos aislado para medir la generalización del modelo ante escenarios 100% nuevos.

La Mecánica de Aprender (El Ciclo de Entrenamiento)



Entrenar no es un cálculo único; es un proceso iterativo de reducción sistemática de errores.

Anatomía Interna: Parámetros y Función de Pérdida



Parámetros del Modelo (Pesos y Bias):

Valores matemáticos internos que determinan cómo las entradas (X) se transforman en predicciones ($\hat{y}$).

Son las "perillas" que el modelo ajusta.

Función de Pérdida (Loss Function):


Fórmula que cuantifica matemáticamente la magnitud del error entre la predicción ($\hat{y}$) y la realidad (y).

Parámetros Aleatorios → Entrenamiento iterativo → Ajuste por Loss Function → Parámetros Óptimos

Evaluación Objetiva del Modelo

No basta con observar ejemplos aislados; requerimos métricas de evaluación rigurosas sobre el Dataset de Test.

$$\text{Accuracy} = \frac{\text{Predicciones Correctas}}{\text{Total de Predicciones}}$$



Exactitud (Accuracy): Métrica fundamental en problemas de clasificación. Si el modelo procesa 100 imágenes y acierta en 85, el Accuracy es del 85% (0,85).

Matriz Comparativa: Entrenamiento vs. Inferencia


Fase de Training (Construcción)

- **Datos:** Históricos, masivos y etiquetados ($X + y$).
- **Operación:** Ciclos múltiples (iteraciones), cálculo de error, ajuste constante de parámetros.
- **Infraestructura:** Alta demanda computacional (Cloud, GPU).

Fase de Inferencia (Producción)

- **Datos:** Datos nuevos, un registro a la vez, sin etiqueta (X aislada).
- **Operación:** Ejecución de una sola vía (Forward), los parámetros son estáticos.
- **Infraestructura:** Ejecución rápida, implementable en dispositivos móviles o servidores locales.

Pipeline End-to-End (Las 12 Fases)



Del Diseño a Python (Proyecto Integrador)



```
X, y = cargar_datos()  
X_train, X_test = dividir_dataset(X, y)  
  
modelo = crear_modelo_cnn()  
modelo.train(X_train, y_train)  
modelo.evaluate(X_test, y_test)  
  
prediccion = modelo.predict(nueva_imagen)
```

Proyecto Integrador CNN

Problema: Clasificar residuos (plástico, vidrio, cartón, metal).

Progresión: Evolución desde redes básicas hacia Redes Neuronales Convolucionales (CNN).

Inferencia Esperada:

Nueva foto → Modelo entrenado → 'Vidrio (91%)'.

Casos de Discusión en Clase



Caso 1:

Precios históricos de viviendas. ¿Qué variable corresponde a X y cuál a y?



Caso 2:

Un modelo alcanza 99% de Accuracy evaluado con sus propios datos de Training. ¿Es confiable en producción?



Caso 3: Una App móvil que reconoce una fruta desde la cámara. ¿El modelo está entrenando o haciendo inferencia?



Caso 4: Descargamos 1,000 imágenes de árboles, pero ninguna tiene nombre. ¿Podemos aplicar aprendizaje supervisado directamente?

Síntesis de la Semana 3

Aprendizaje Supervisado: Fundamentos

1. Se requiere X (entradas) + y (etiquetas) para predecir $\hat{y}$.

2. Las características (Features) son la base predictiva; la etiqueta es el objetivo.

3. Entrenar es un ajuste iterativo de parámetros.

4. El objetivo del aprendizaje es minimizar la función de pérdida (error).


5. Existe una brecha operativa radical entre (crear) e inferencia (usar).

7. El Pipeline end-to-end (Datos $\rightarrow$ Entrenamiento $\rightarrow$ Evaluación $\rightarrow$ Inferencia) es la base del Proyecto Integrador.

6. La evaluación exige métricas objetivas (ej. Accuracy) sobre un Dataset separado (Test).

7. El Pipeline end-to-end (Datos $\rightarrow$ Entrenamiento $\rightarrow$ Evaluación $\rightarrow$ Inferencia) es la base del Proyecto Integrador.

Hacia la Semana 4: Abriendo la Caja Negra



Hemos cubierto el QUÉ y el CÓMO a nivel de sistema macro. La próxima semana bajaremos al nivel micro.

¿Cómo aprende exactamente la máquina por dentro?

Introducción a las Redes Neuronales Artificiales.

Exploraremos: Neurona artificial, Capas, Pesos, Funciones de Activación y Backpropagation.

Preparación para el primer modelo base del Proyecto Integrador.