



La materia prima del Machine Learning

Semana 5 — Preparación, auditoría y estructuración de datos para modelos de clasificación.





Proyecto Integrador
CNN: Clasificación
de Residuos




Dr. Julio Lopez-Nunez

Un algoritmo sofisticado no compensa un Dataset deficiente

Unidad 1: Foco en la mecánica

FLUJO HISTÓRICO

VERSIÓN 1.0




Foco previo: Entender la mecánica interna del modelo y el algoritmo.

VERSIÓN 1.0

Unidad Actual: Foco en la materia prima

CICLO ACTIVO

ENFOQUE PRINCIPAL



La calidad del modelo depende fuertemente de la calidad de los datos utilizados para entrenarlo. Auditar la materia prima es el paso más crítico del proyecto.

ALERTA CRÍTICA: AUDITORÍA DE DATOS

MATERIAL FUENTE

Anatomía estructural: Features y Labels

Cada fila o imagen individual constituye una observación.

Panel A: Datos Tabulares


⚙️ **Features (X) :**
La información
para aprender

Edad	Ingresos	Compras	Cliente Frecuente
35	45000	12	Sí
28	32000	5	No

🎯 **Label (y) :**
El resultado a
predecir

Panel B: Visión Computacional (Imágenes)


🖼️ **Features (X) :**
Matriz de píxeles



🏷️ **Label (y) :**
Categoría

El espectro de la información: Estructurados vs. No estructurados

Datos Estructurados




- Posición y significado predefinidos.
- Representan cantidades o categorías exactas.
- Formatos: CSV, SQL, Hojas de cálculo.

Stock = 12 | Precio = \$65.000

Dominio de nuestro clasificador CNN

Datos No Estructurados



- Sin estructura tabular tradicional.
- La información reside en patrones, frecuencias o píxeles.
- Formatos: JPG, PNG, MP3, TXT.

Una fotografía no tiene una columna que diga "Ruedas=4" o "Tipo=Vehículo".

Diseño inverso: Los datos responden al problema



NUNCA comiences preguntando "¿Qué Dataset podemos conseguir?" sin haber definido "¿Qué problema queremos resolver?".


Las cuatro dimensiones de un Dataset de alto valor

APRENDIZAJE DE CALIDAD

Volumen

Dictado por la dificultad del problema.

Más datos no significa automáticamente mejores datos.



Representatividad

Debe reflejar la variabilidad del entorno real de producción, no solo el entorno de laboratorio.



Diversidad

Alta variabilidad intra-clase (múltiples ángulos, tamaños, fondos e iluminaciones por categoría).



Consistencia

Criterios de etiquetado uniformes, precisos y sin ambigüedades.




Un dataset masivo lleno de imágenes idénticas de laboratorio fracasará en el mundo real.

Matriz de diagnóstico clínico para patologías de datos.

Patología	Síntoma Frecuente	Impacto Matemático	
	Desbalance de Clases	90% Plástico, 10% Vidrio.	Falsa Accuracy. El modelo predice siempre la clase mayoritaria sin aprender patrones.
	Datos Duplicados	1,500 copias idénticas en 5,000 archivos.	Falsa sensación de diversidad. Fuga de datos (Data Leakage) hacia el set de Test.
	Errores de Etiquetado	Lata de metal guardada en la carpeta 'Cartón'.	Contradicción técnica. La red neuronal ajusta sus pesos hacia patrones equivocados.
	Sesgos (Bias)	Vehículos fotografiados exclusivamente de día.	Incapacidad total de generalización en condiciones no representadas.

Estructura de directorios en el proyecto integrador

La jerarquía del sistema operativo define la etiqueta (y).



Peligro de Correlación Espuria

Si todo el plástico se fotografía sobre fondo blanco y todo el vidrio sobre fondo negro, la CNN aprenderá la regla errónea: **Fondo = Categoría**, ignorando el material real del objeto.


Estandarización técnica para modelos de visión



4000x3000, JPG crudo



Preprocesamiento




Tensor numérico
estandarizado, ej. 300x300



Resolución y Dimensiones:

- El modelo requiere tensores uniformes.



Relación de Aspecto:

- Evitar deformaciones morfológicas al redimensionar.



Canales de Color:

- RGB (3 canales) vs. Escala de grises (1 canal).



Formatos Soportados:

- Consistencia en JPG, PNG, o WEBP.

Pasos críticos aplicados antes del Training: Redimensionamiento y Normalización.

Estrategias de adquisición: ¿Construir o reutilizar?

Dataset Existente (Repositorios, APIs)




Pros

- Rapidez de acceso y alto volumen.
- Etiquetas preexistentes.



Contras

- Sesgos heredados del creador.
- Taxonomía de clases puede estar desalineada con nuestro objetivo.




Dataset Propio (Captura directa)



Pros

- Control absoluto sobre la diversidad.
- Máxima alineación con el problema de negocio específico.




Contras

- Adquisición lenta.
- Requiere proceso intensivo de etiquetado manual.

Veredicto Estratégico: Se recomienda un enfoque mixto (Dataset público + imágenes propias capturadas), validando rigurosamente la consistencia técnica entre ambas fuentes.

El ciclo de vida continuo de los datos



Los datos no son un paso previo desechable; forman parte del sistema circulatorio continuo del modelo en producción.

Inspección inicial: Código Python y revisión crítica

Análisis Automatizado

```
import os

# Revisión de estructura y volumen
clases = os.listdir('dataset_residuos/')
print(f'Clases: {clases}')

cantidad = len(os.listdir('dataset_residuos/plastico/'))
print(f'Total imágenes Plástico: {cantidad}')
```

Análisis Visual Crítico



-  - Archivos corruptos o ilegibles.
-  - Objetos principales demasiado pequeños o borrosos.
-  - Errores de semántica (Labels incorrectos).
-  - Fondos artificialmente repetitivos.

La cadena de valor del aprendizaje automático




Preparar correctamente los datos es un riguroso ejercicio de ingeniería de software, no una simple tarea administrativa de recolección.

Casos de diagnóstico rápido

Caso 1: Volumen vs. Desbalance

5,000 fotos de Clase A; solo 100 fotos de las Clases B, C y D.

¿Qué riesgo matemático corre nuestra métrica de Accuracy?



Caso 2: Representatividad vs

Modelo entrenado **100%** con **fondos de estudio fotográfico**, pero desplegado en una cámara de **smartphone** en la calle.

¿Por qué fallará la predicción?

Caso 3: Diversidad vs. Duplicidad

Dataset descargado de **10,000 imágenes**, pero **3,000 son copias binarias exactas**.

¿Por qué el conteo de archivos es un espejismo?

Caso 4: Calidad de Labels

La carpeta '**vidrio**' contiene numerosas fotografías de **botellas de PET transparente**.

¿Qué aprenderá exactamente la red neuronal?

Síntesis y puente hacia la preparación práctica

Postulados Críticos

- ✓ **Features** y **Labels** confiables son la única forma de aprendizaje supervisado.
- ✓ El diseño es inverso: el problema de negocio dicta los datos, no la disponibilidad.
- ✓ Cantidad, representatividad, diversidad y balance no son sinónimos; todos deben auditarse.
- ✓ En visión computacional, la carpeta física en el sistema estructura el **Label** digital.



Próximamente: Semana 6

De la auditoría a la acción

¿Cómo transformar imágenes crudas en tensores matemáticos?

- ✓ Limpieza automatizada.
- ✓ **Data Augmentation** para combatir escasez.
- ✓ Segmentación crítica: Training / Validation / Test.