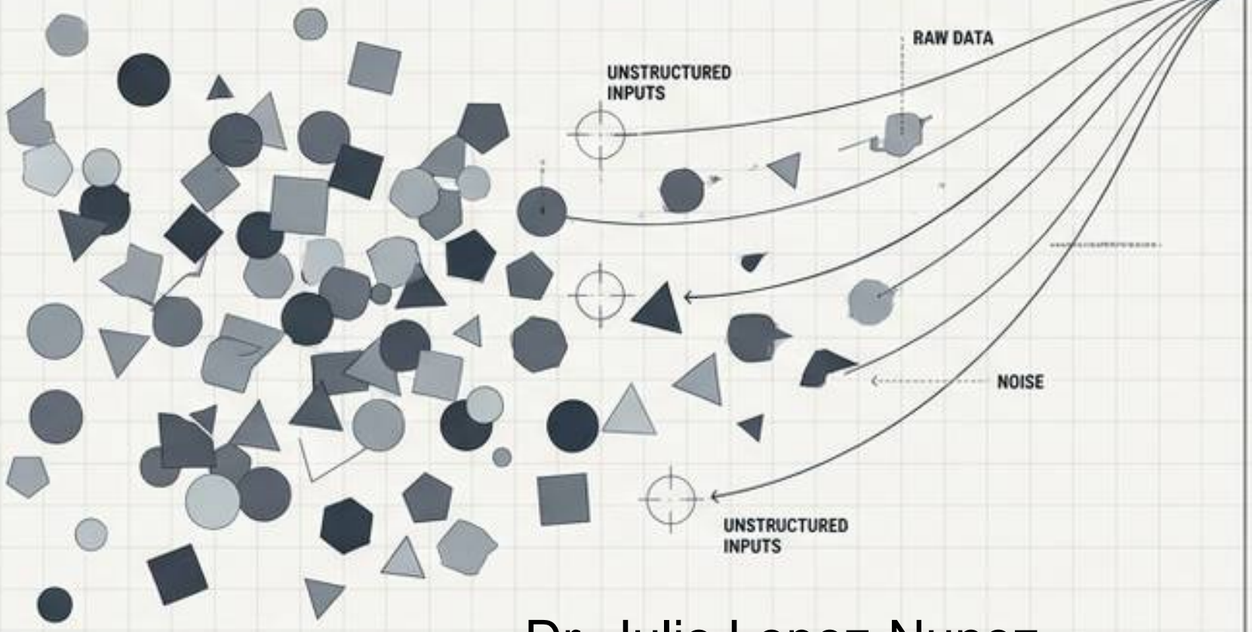
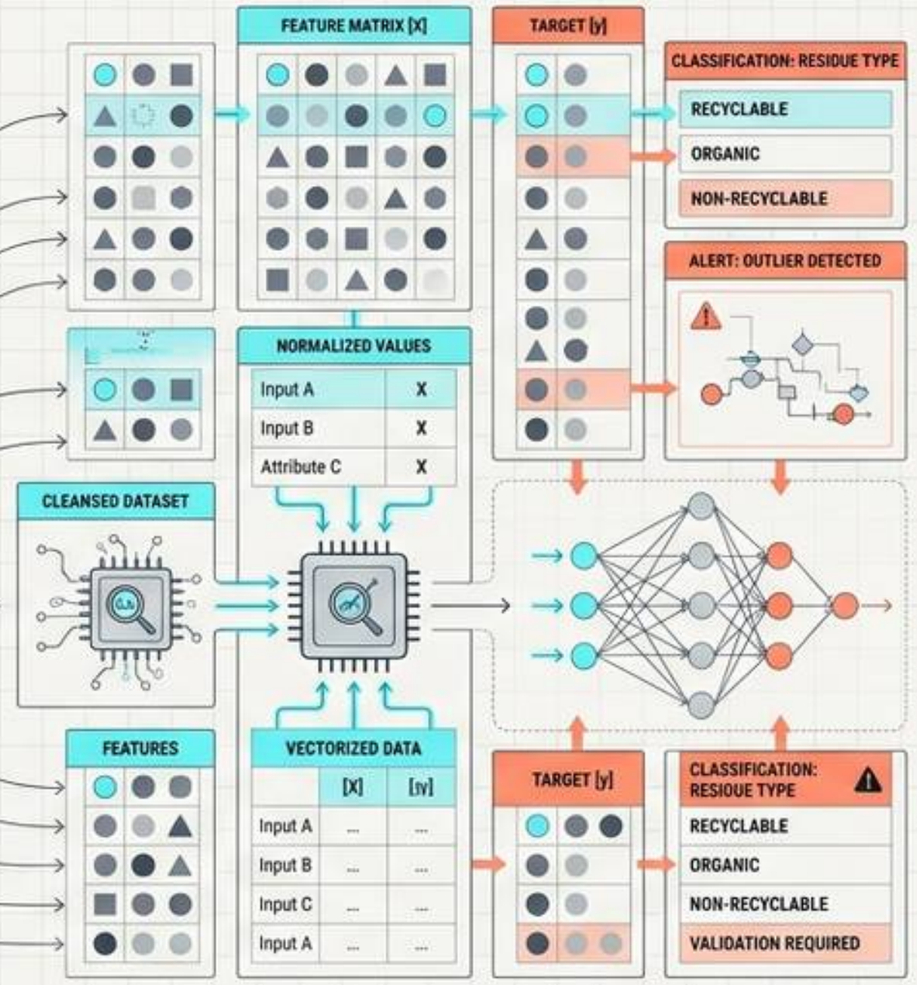
La materia prima del Machine Learning

Semana 5 — Preparación, auditoría y estructuración de datos para modelos de clasificación.





Proyecto Integrador
CNN: Clasificación de Residuos

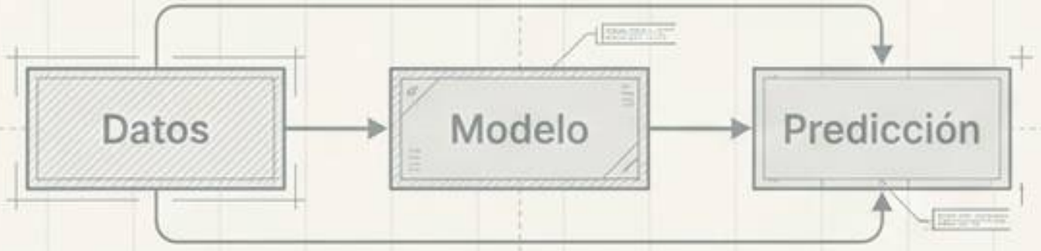
Dr. Julio Lopez-Nunez

Un algoritmo sofisticado no compensa un Dataset deficiente

Unidad 1: Foco en la mecánica

FLUJO HISTÓRICO

VERSIÓN 1.0



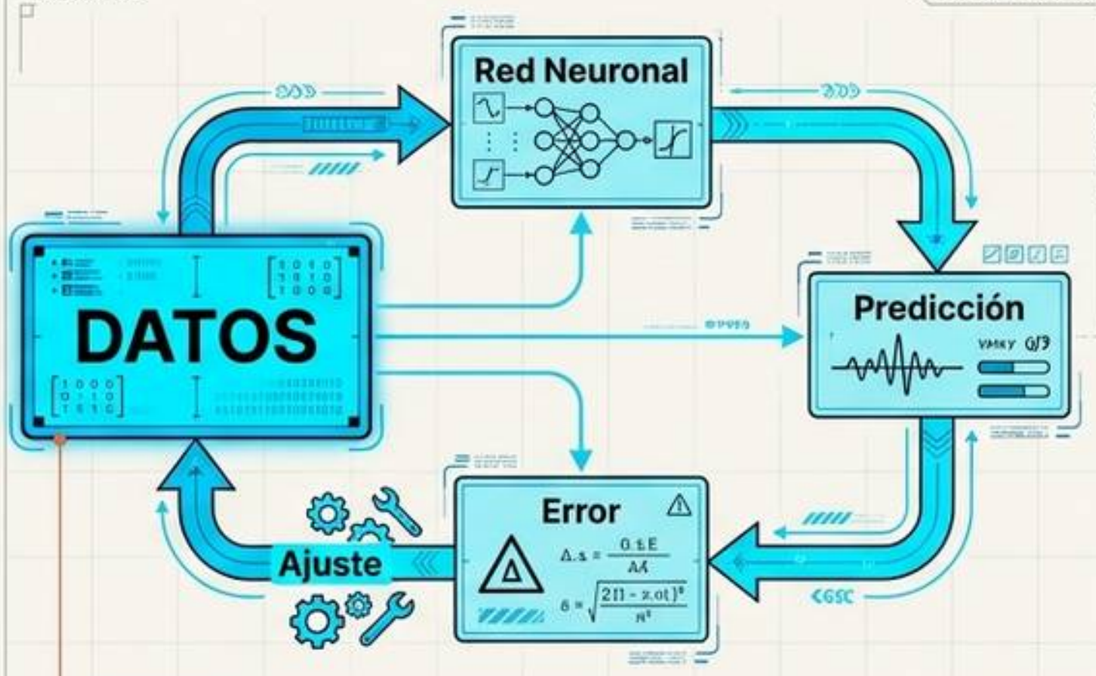
Foco previo: Entender la mecánica interna del modelo y el algoritmo.

VERSIÓN 1.0

Unidad Actual: Foco en la materia prima

CICLO ACTIVO

ENFOQUE PRINCIPAL



La calidad del modelo depende fuertemente de la calidad de los datos utilizados para entrenarlo. Auditar la materia prima es el paso más crítico del proyecto.

ALERTA CRÍTICA: AUDITORÍA DE DATOS

MATERIAL FUENTE

Gemini Notebook

Anatomía estructural: Features y Labels

Cada fila o imagen individual constituye una observación.

Panel A: Datos Tabulares

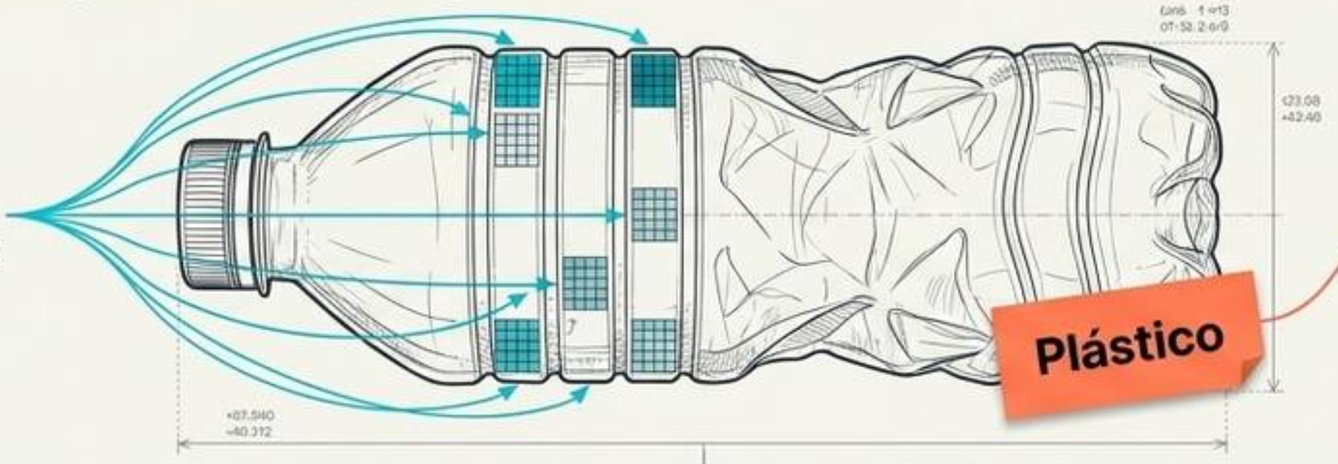
Features (X) :
La información para aprender

Edad	Ingresos	Compras	Cliente Frecuente
35	45000	12	Sí
28	32000	5	No

Label (y) :
El resultado a predecir

Panel B: Visión Computacional (Imágenes)

Features (X) :
Matriz de píxeles

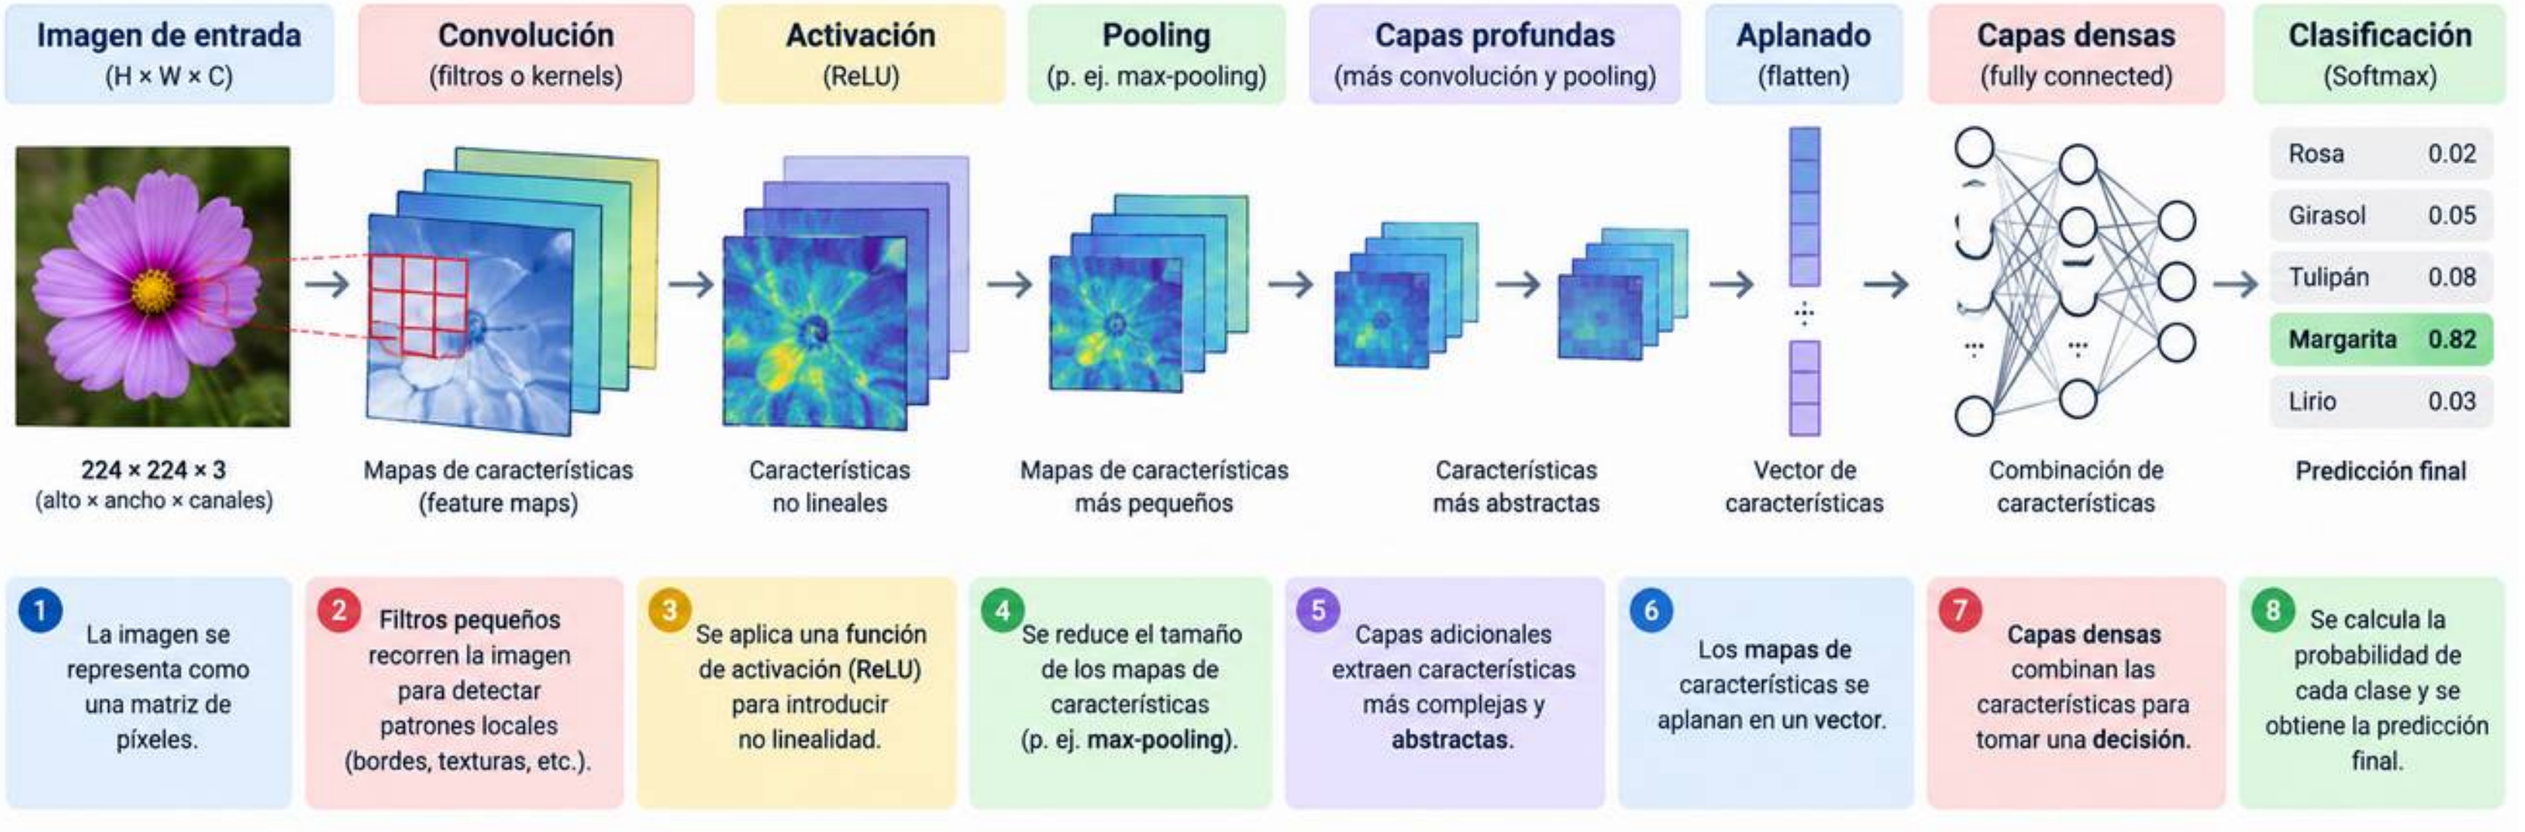


Label (y) :
Categoría

Gemini Notebook

¿Cómo funciona una Red Neuronal Convolucional (CNN)?

Una CNN procesa una imagen a través de varias capas que extraen características visuales de forma automática y las utilizan para hacer una predicción.



1. La imagen se representa como una matriz de píxeles.
2. Filtros pequeños recorren la imagen para detectar patrones locales (bordes, texturas, etc.).
3. Se aplica una función de activación (ReLU) para introducir no linealidad.
4. Se reduce el tamaño de los mapas de características (p. ej. max-pooling).
5. Capas adicionales extraen características más complejas y abstractas.
6. Los mapas de características se aplanan en un vector.
7. Capas densas combinan las características para tomar una decisión.
8. Se calcula la probabilidad de cada clase y se obtiene la predicción final.

Practica: https://poloclub.github.io/cnn-explainer/

Ref.: https://youtu.be/QzY57FaENXg?si=LjQoh93CcM6zKHPP

Conceptos fundamentales de una Red Neuronal Convolucional (CNN)

Las CNN utilizan filtros, convolución y pooling para extraer características visuales de las imágenes.

1 Filtros o kernels

Pequeñas matrices que recorren la imagen para detectar patrones locales.

Filtro 3 × 3

-1	0	1
-1	0	1
-1	0	1



El filtro se desliza por la imagen realizando multiplicaciones.

Ejemplos de filtros comunes:

-1	0	1
-1	0	1
-1	0	1

Detección de bordes (verticales)

0	1	0
1	-4	1
0	1	0

Detección de líneas

1	1	1
1	1	1
1	1	1

Suavizado de texturas

2 Convolución

Se aplica el filtro en cada región de la imagen para extraer características.



Región de la imagen (3 × 3 píxeles)

120	125	130
118	119	124
115	116	120

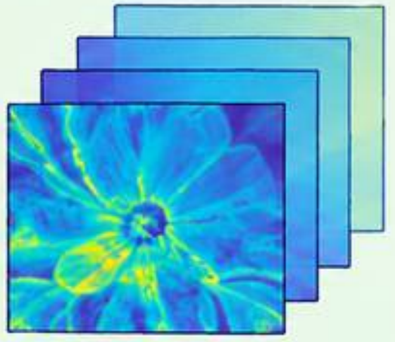
Filtro 3 × 3

-1	0	1
-1	0	1
-1	0	1

La convolución genera un nuevo valor para cada posición, produciendo un mapa de características.

3 Mapas de características

El resultado de aplicar un filtro a toda la imagen es un mapa de características (feature map).



Valores altos

Valores bajos

Mapa de características

Cada filtro produce un mapa de características que resalta un patrón específico (bordes, líneas, texturas, etc.). La red aprende automáticamente múltiples filtros durante el entrenamiento.

4 Pooling (max-pooling)

Reduce el tamaño de los mapas de características, manteniendo la información más importante.

Mapa de características (ejemplo)

2	3	1	0
0	1	2	1
4	6	1	2
3	1	1	0

Max-pooling (2 × 2) →

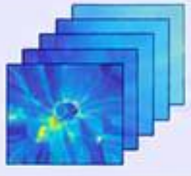
Mapa reducido

3	2
6	2

En max-pooling se toma el valor más alto de cada región (por ejemplo, 2 × 2).

- Reduce el tamaño del mapa de características.
- Disminuye la complejidad computacional.
- Aumenta la robustez ante pequeñas variaciones en la imagen.

De patrones simples a patrones complejos

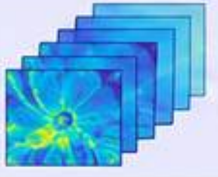


Capas iniciales: características simples

→

Las primeras capas de una CNN detectan características simples (bordes, líneas, texturas), mientras que las capas más profundas aprenden representaciones cada vez más complejas y abstractas.

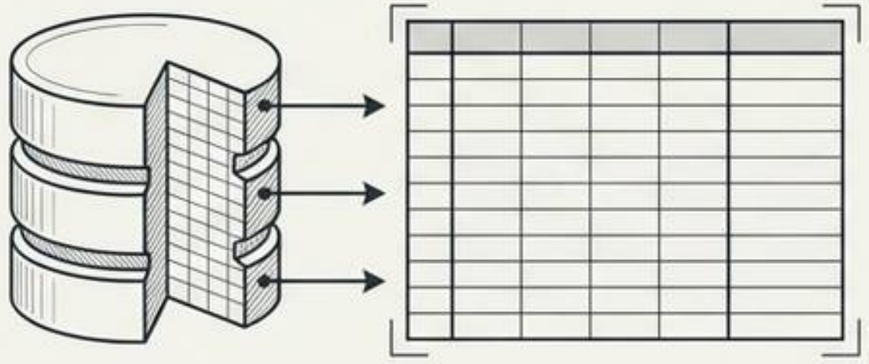
→



Capas profundas: patrones complejos

El espectro de la información: Estructurados vs. No estructurados

Datos Estructurados

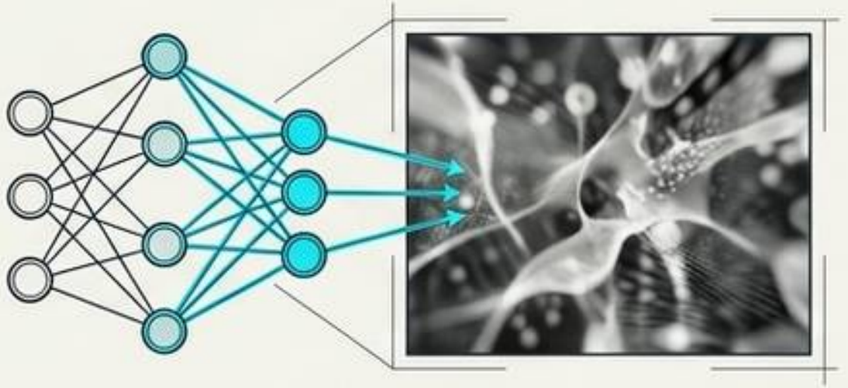


- Posición y significado predefinidos.
- Representan cantidades o categorías exactas.
- Formatos: CSV, SQL, Hojas de cálculo.

Stock = 12 | Precio = $65.000

Dominio de nuestro clasificador CNN

Datos No Estructurados



- Sin estructura tabular tradicional.
- La información reside en patrones, frecuencias o píxeles.
- Formatos: JPG, PNG, MP3, TXT.

Una fotografía no tiene una columna que diga "Ruedas=4" o "Tipo=Vehículo".

Gemini Notebook

Diseño inverso: Los datos responden al problema



1. Problema

Clasificar automáticamente distintos tipos de residuos urbanos.



2. Objetivo del Modelo

Determinar la categoría exacta a partir de una única fotografía.



3. Datos Necesarios

Fotografías representativas de cada tipo de residuo.



4. Labels

[Plástico, Vidrio, Cartón, Metal]



NUNCA comiences preguntando "¿Qué Dataset podemos conseguir?" sin haber definido "¿Qué problema queremos resolver?".

Gemini Notebook

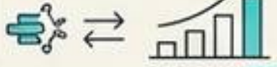
Las cuatro dimensiones de un Dataset de alto valor

APRENDIZAJE DE CALIDAD

Volumen

Dictado por la dificultad del problema.

Más datos no significa automáticamente mejores datos.



Representatividad

Debe reflejar la variabilidad del entorno real de producción, no solo el entorno de laboratorio.



Diversidad

Alta variabilidad intra-clase (múltiples ángulos, tamaños, fondos e iluminaciones por categoría).



Consistencia

Criterios de etiquetado uniformes, precisos y sin ambigüedades.



Un dataset masivo lleno de imágenes idénticas de laboratorio fracasará en el mundo real.

Gemini Notebook

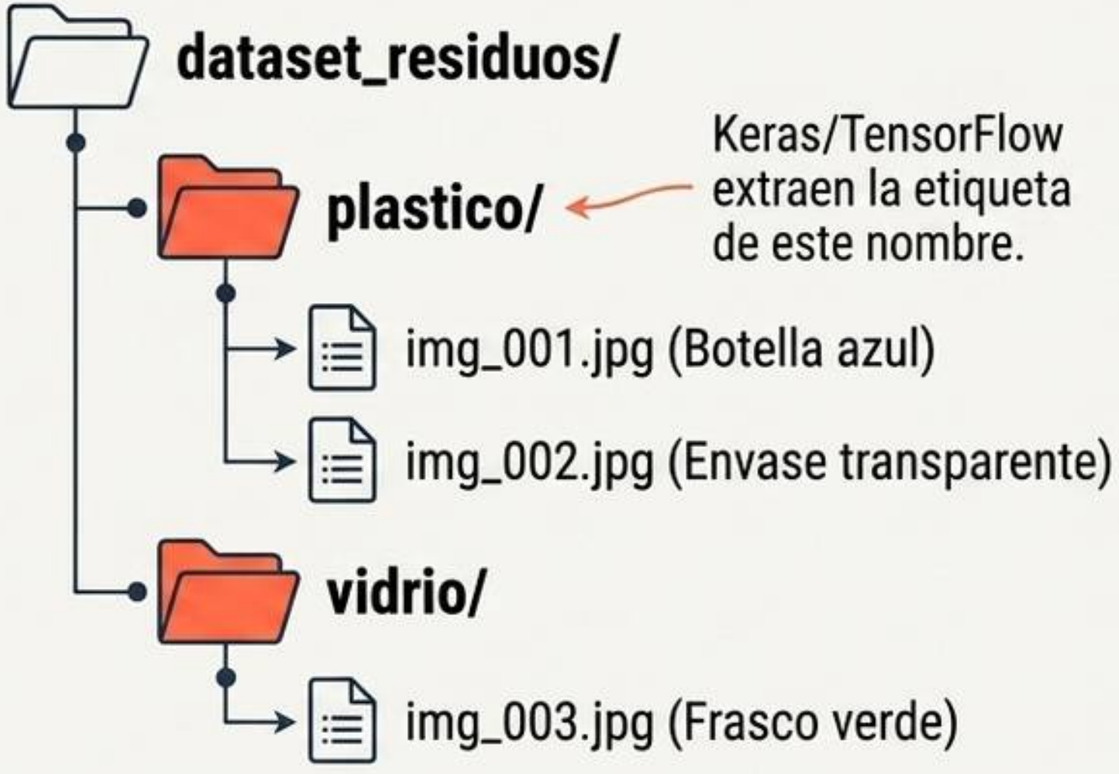
Matriz de diagnóstico clínico para patologías de datos.

Patología	Síntoma Frecuente	Impacto Matemático
 **Desbalance de Clases**	90% Plástico, 10% Vidrio.	Falsa Accuracy. El modelo predice siempre la clase mayoritaria sin aprender patrones.
 **Datos Duplicados**	1,500 copias idénticas en 5,000 archivos.	Falsa sensación de diversidad. Fuga de datos (Data Leakage) hacia el set de Test.
 **Errores de Etiquetado**	Lata de metal guardada en la carpeta 'Cartón'.	Contradicción técnica. La red neuronal ajusta sus pesos hacia patrones equivocados.
 **Sesgos (Bias)**	Vehículos fotografiados exclusivamente de día.	Incapacidad total de generalización en condiciones no representadas.

Gemini Notebook

Estructura de directorios en el proyecto integrador

La jerarquía del sistema operativo define la etiqueta (y).



Peligro de Correlación Espuria

Si todo el plástico se fotografía sobre fondo blanco y todo el vidrio sobre fondo negro, la CNN aprenderá la regla errónea: **Fondo = Categoría**, ignorando el material real del objeto.

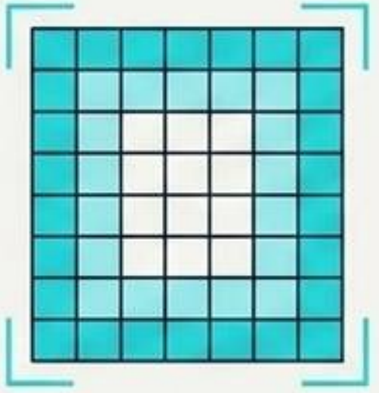
Gemini Notebook

Estandarización técnica para modelos de visión



4000x3000, JPG crudo

Preprocesamiento



Tensor numérico estandarizado, ej. 300x300

Resolución y Dimensiones:

- El modelo requiere tensores uniformes.

Canales de Color:

- RGB (3 canales) vs. Escala de grises (1 canal).

Relación de Aspecto:

- Evitar deformaciones morfológicas al redimensionar.

Formatos Soportados:

- Consistencia en JPG, PNG, o WEBP.

Pasos críticos aplicados antes del Training: Redimensionamiento y Normalización.

Gemini Notebook

Estrategias de adquisición: ¿Construir o reutilizar?

Dataset Existente (Repositorios, APIs)

Pros

- Rapidez de acceso y alto volumen.
- Etiquetas preexistentes.

Contras

- Sesgos heredados del creador.
- Taxonomía de clases puede estar desalineada con nuestro objetivo.

Dataset Propio (Captura directa)

Pros

- Control absoluto sobre la diversidad.
- Máxima alineación con el problema de negocio específico.

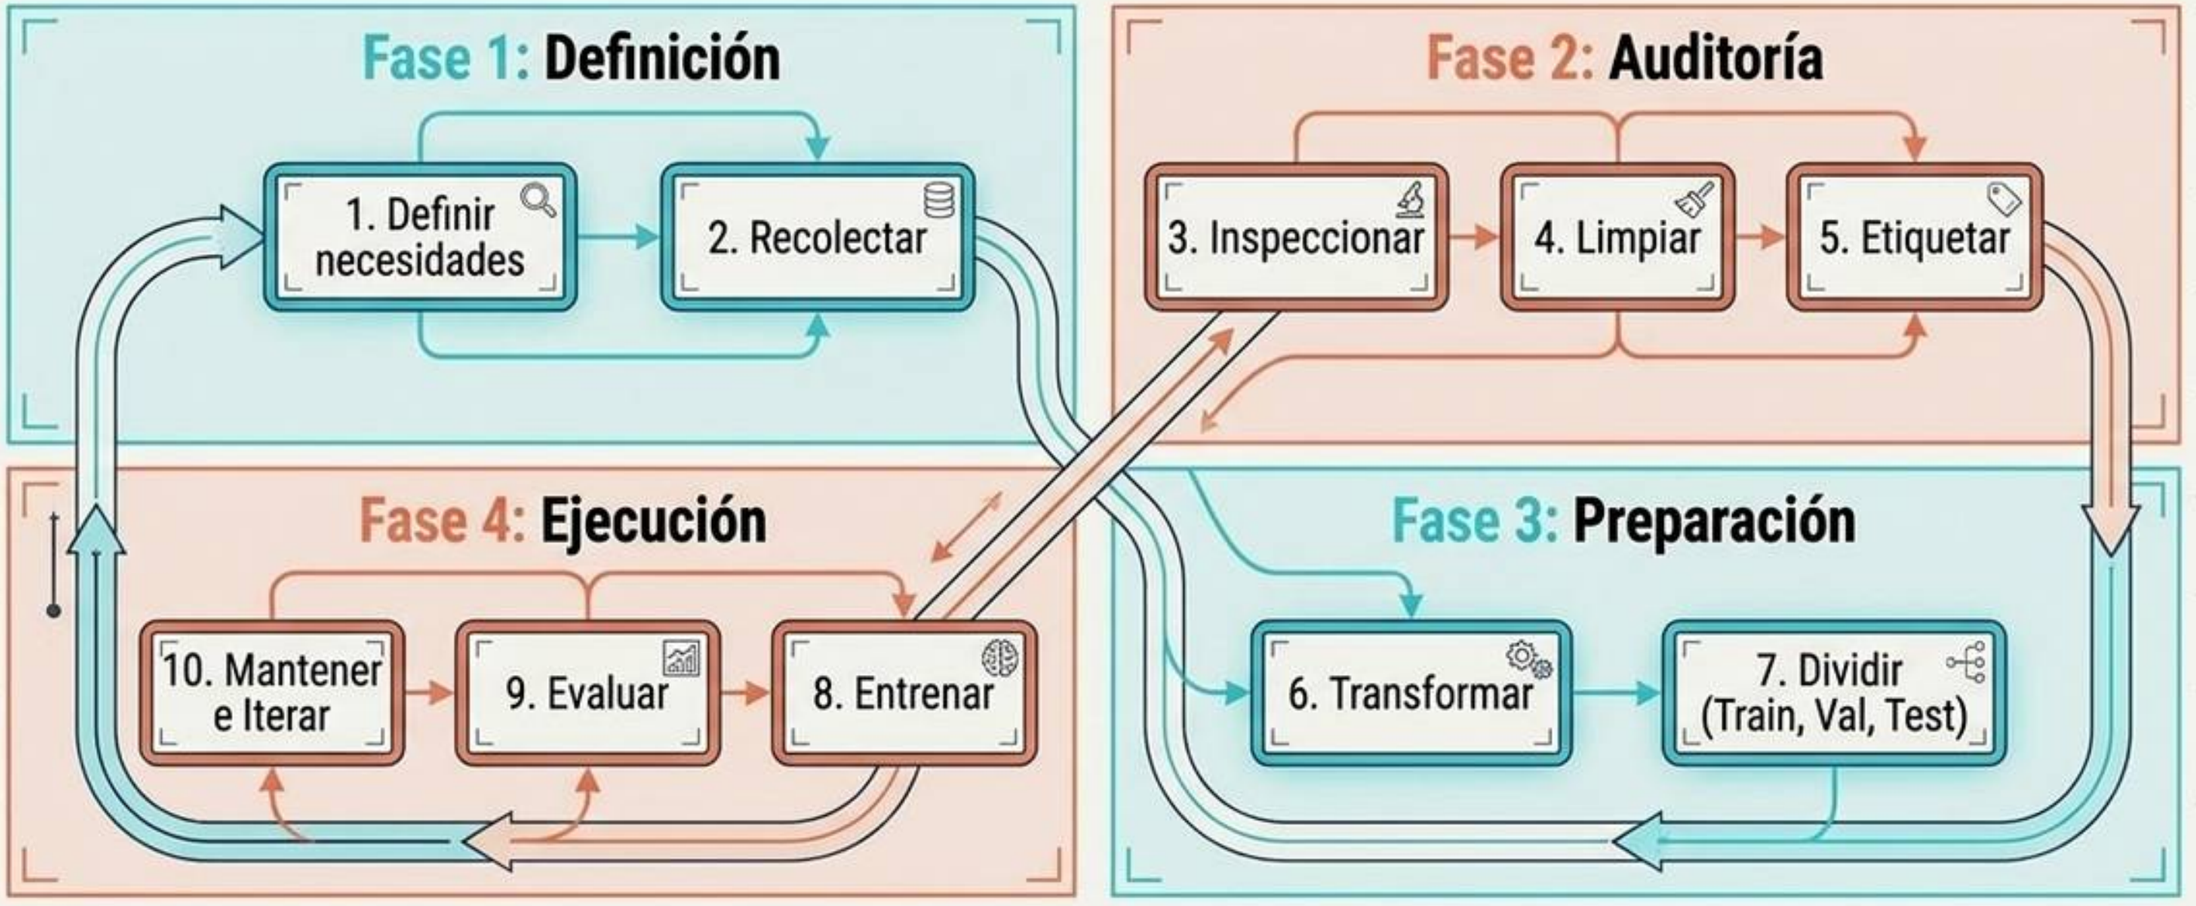
Contras

- Adquisición lenta.
- Requiere proceso intensivo de etiquetado manual.

Veredicto Estratégico: Se recomienda un enfoque mixto (Dataset público + imágenes propias capturadas), validando rigurosamente la consistencia técnica entre ambas fuentes.

Gemini Notebook

El ciclo de vida continuo de los datos



Los datos no son un paso previo desechable; forman parte del sistema circulatorio continuo del modelo en producción.

Gemini Notebook

Inspección inicial: Código Python y revisión crítica

Análisis Automatizado

```python
import os

# Revisión de estructura y volumen
clases = os.listdir('dataset_residuos/')
print(f'Clases: {clases}')

cantidad = len(os.listdir('dataset_residuos/plastico/'))
print(f'Total imágenes Plástico: {cantidad}')
```

Análisis Visual Crítico



- Archivos corruptos o ilegibles.
- Objetos principales demasiado pequeños o borrosos.
- Errores de semántica (Labels incorrectos).
- Fondos artificialmente repetitivos.

Gemini Notebook

La cadena de valor del aprendizaje automático



Preparar correctamente los datos es un riguroso ejercicio de ingeniería de software, no una simple tarea administrativa de recolección.

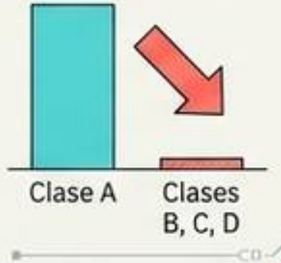
Gemini Notebook

Casos de diagnóstico rápido

Caso 1: Volumen vs. Desbalance

5,000 fotos de Clase A; solo 100 fotos de las Clases B, C y D.

¿Qué riesgo matemático corre nuestra métrica de Accuracy?



Caso 2: Representatividad



Modelo entrenado **100%** con **fondos de estudio fotográfico**, pero desplegado en una cámara de smartphone en la calle.

¿Por qué fallará la predicción?

Caso 3: Diversidad vs. Duplicidad

Dataset descargado de **10,000 imágenes**, pero **3,000 son copias binarias exactas**.

¿Por qué el conteo de archivos es un espejismo?

Caso 4: Calidad de Labels

La carpeta '**vidrio**' contiene numerosas fotografías de **botellas de PET transparente**.

¿Qué aprenderá exactamente la red neuronal?

Gemini Notebook