

Machine Learning 2026 — Semana 6

Preparación y Etiquetado de Datos

De imágenes crudas a un Dataset listo para Deep Learning.



El Camino Hacia un Dataset Utilizable

Disponer de millones de imágenes no equivale a tener un buen Dataset. La preparación es una etapa crítica diseñada para aislar y reducir problemas en los datos de origen antes de que afecten el entrenamiento del modelo.

The Refining Pipeline



Diagnóstico y Limpieza de Anomalías

Antes de modificar los datos, establecemos una línea base respondiendo: ¿Cuántas imágenes y clases hay? ¿Qué dimensiones tienen? Todo elemento que no aporte valor debe ser filtrado.

Anomalia		Problema Visual	Acción
Archivos Corruptos		La imagen no se puede abrir.	Eliminar o recuperar.
Irrelevantes		No pertenece a ninguna clase del problema.	Descartar.
Borroso		Sin información suficiente para identificar.	Descartar.
Duplicados		Alteran la evaluación artificialmente.	Limpiar ANTES de dividir.
Mala Etiqueta		Asignación incorrecta.	Reubicar.

Detección Automatizada de Archivos Corruptos

Python permite automatizar la validación de archivos antes de integrarlos al pipeline. La función **verify()** permite identificar archivos dañados de manera eficiente sin cargar la imagen entera en memoria.

```
from PIL import Image
import os

for archivo in os.listdir("dataset/plastico/"):
    try:
        img = Image.open(f"dataset/plastico/{archivo}")
        img.verify()
    except:
        print(f"Archivo corrupto detectado: {archivo}")
```



Arquitectura de Directorios y Nomenclatura

Una estructura de carpetas bien diseñada permite que bibliotecas de Machine Learning infieran automáticamente las etiquetas.

Reglas de consistencia:

- Uso exclusivo de minúsculas.
- Ausencia de espacios o caracteres especiales.
- Nombres breves y descriptivos.

✗ Mala Práctica




✓ Buena Práctica




Gestión de Ambigüedad en el Etiquetado

En el aprendizaje supervisado requerimos una asociación estricta: **1 Imagen = 1 Clase**. Si una persona experta no puede determinar claramente la clase de una imagen, esta no será un buen ejemplo para entrenar a la red neuronal.




Homologación Geométrica: Redimensionamiento

Las redes neuronales exigen dimensiones de entrada consistentes. Forzar una imagen rectangular a un formato cuadrado genera deformación destructiva. Dependiendo del problema, se debe elegir estratégicamente entre recortar (Crop) o rellenar (Padding).



De Píxeles a Tensores Numéricos


El modelo no percibe objetos, sino representaciones matriciales matemáticas. El pipeline debe estandarizar y mantener una representación de canales coherente para todo el Dataset.



Estabilización Matemática mediante Normalización

Transformar los valores de los píxeles hacia una escala reducida (Valor Normalizado = Valor Original / 255). Trabajar con escalas numéricas controladas (0 a 1) facilita la convergencia y estabiliza el cálculo matemático.

Antes y Después

	Píxel Original (0-255) 🗄️		Píxel Normalizado (0-1) 📄
	0	→	0.000
	128	→	0.502
	255	→	1.000




Keras Implementation (Python)

```
from tensorflow.keras.layers import Rescaling  
  
capa_normalizacion = Rescaling(1./255)
```



Invarianza: Transformar la Imagen $\neq$ Alterar la Etiqueta

Cualquier operación geométrica o matemática cambia únicamente la representación de los datos, no su significado semántico. Regla de Oro: Se debe mantener intacta la asociación bidireccional estructural: Entrada Transformada $\leftrightarrow$ Etiqueta Original.



Arquitectura de División Funcional del Dataset


El conjunto total debe separarse para que el modelo aprenda y se evalúe sin trampas.



Control de Calidad: Estratificación y Fuga de Datos


División Estratificada (Correcto)

Garantiza que las proporciones de cada clase se mantengan idénticas en todos los subconjuntos.



Fuga de Datos / Data Leakage (Error Fatal)

Ocurre cuando el modelo es evaluado con ejemplos que ya memorizó.
Solución: Eliminar duplicados antes de dividir.




Error: Dato duplicado en Test bypasses aislamiento.
Uneliminacio de dacato.

Trazabilidad y Carga Automatizada con Keras

Un Dataset no es una simple carpeta, es un **proyecto reproducible**. Nunca sobrescribir las imágenes fuente; documentar todo el flujo numérico.

Arquitectura de Trazabilidad



Ejecución Automatizada

Si la estructura en disco es correcta, Keras automatiza la carga, el redimensionamiento y la generación de lotes (batches).

```
dataset_train = image_dataset_from_directory(  
    'datos_procesados/train/',  
    image_size=(224, 224),  
    batch_size=32  
)
```


Proyecto CNN: Construyendo el Dataset de Residuos

Su entregable debe documentar la metamorfosis de los datos. No presenten una simple colección de fotografías; presenten un Dataset estructurado para Deep Learning. Se evaluará la trazabilidad **numérica** desde la recolección hasta la separación funcional.



Síntesis Semanal y Próximos Pasos

El pipeline está completo:



La limpieza aísla errores; el etiquetado exige reglas sin ambigüedad.



Transformaciones geométricas y numéricas preparan el tensor sin alterar la semántica.



La división estratégica (Train, Val, Test) previene la Fuga de Datos.

Hacia la Semana 7

Ya sabemos preparar los datos para alimentar al modelo. La pregunta crítica ahora es: **¿Cómo sabemos si nuestra CNN realmente aprendió a generalizar o si simplemente memorizó los datos de entrenamiento?**

