





Semana 8: Validación de Modelos y Data Augmentation

Estrategias robustas para la evaluación y el enriquecimiento de datos en Machine Learning

La fragilidad de una única partición

El modelo no cambió. Lo que cambió fue la composición aleatoria de los datos.




Takeaway: Un solo split puede entregar una estimación demasiado sensible a la muestra.

La mecánica del K-Fold Cross-Validation

Dividir los datos en k subconjuntos (folds). Entrenar k veces, **rotando el bloque de validación**.

Output: Entrega un **Accuracy promedio** y revela la **estabilidad** del modelo (ej. variación de **87%-91%**).



El costo computacional en Deep Learning

El proyecto integrador priorizaremos el uso de Train / Validation / Test de única partición.


Machine Learning Tradicional



Algoritmos rápidos

Estrategia:
K-Fold Cross-Validation

Arquitecturas Deep Learning



Entrenamiento lento
y costoso

Estrategia:
Train / Validation / Test


5 folds × 40 min/CNN = 200 minutos

(para evaluar una sola configuración)

Takeaway: K-Fold se reserva para: Datasets pequeños, comparación estricta de parámetros, o recursos abundantes.


Reglas de oro: Estratificación y Aislamiento

1. Stratified K-Fold



Conserva la proporción original de las clases.

2. Aislamiento del Test Set



El Test Set es intocable hasta la evaluación final.

Implementación y Reproducibilidad (Scikit-learn)

Principio Científico: Mismas condiciones → Resultados comparables.

```
from sklearn.model_selection import cross_val_score  
  
resultados = cross_val_score(modelo, X, y, cv=5)
```


```
from sklearn.model_selection import StratifiedKFold  
  
cv_strat = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Fijar una semilla aleatoria garantiza la reproducibilidad de los experimentos.



Data Augmentation: Multiplicando la diversidad

- Incrementar la diversidad efectiva sin recolectar nuevos datos empíricos.
- Obliga a la red a aprender patrones generales en lugar de memorizar píxeles (reduce el Overfitting).



Transformaciones válidas e inválidas

- La transformación modifica la entrada (X) pero jamás debe cambiar el significado real de la clase (y).
- **Context is King:** Un auto invertido verticalmente podría no ser una variación plausible en el mundo real.




Válido



Original



Horizontal Flip



Flip

✓ Clase: Perro
(Conservada)




Inválido



Original



Horizontal Flip




Transformado

✗ Clase Alterada
(Destruye la etiqueta)

El Pipeline Correcto: ¿Dónde aplicamos Augmentation?

- Las transformaciones aleatorias son exclusivas del conjunto de Training.
- Validation y Test deben permanecer estables, representando escenarios reales y consistentes.



Implementación: Offline vs. Online Augmentation

Copiar una imagen idéntica 50 veces no es **augmentation**, es **duplicación inútil**.

Online Augmentation: Produce variaciones infinitas durante el entrenamiento sin colapsar el almacenamiento.

Offline



Generar y guardar copias físicas previas.

Online / Dinámico



Transformaciones al vuelo en cada época
(Integrado en Keras).

```
modelo_augmentation = keras.Sequential([  
    layers.RandomFlip('horizontal'),  
    layers.RandomRotation(0.1),  
    layers.RandomZoom(0.2)  
])
```

Evaluando el impacto del Augmentation


Data augmentation no garantiza automáticamente un mejor modelo; su efecto debe medirse.

- El síntoma de éxito: El desempeño sobre Training baja levemente, pero Validation sube y acorta la brecha de Overfitting.

Sin Augmentation - Peligro de Overfitting



Con Augmentation - Mejor Generalización



El entregable: Consolidación del Dataset Definitivo

La validación de datos precede a la validación del modelo.

Este proceso es el único insumo válido para iniciar el entrenamiento de la CNN en la Unidad 3.



Síntesis de la Semana 8 (8 Ideas Fundamentales)



1. Una partición única es frágil ante el azar.



2. K-Fold estabiliza la métrica evaluando combinaciones.



3. El Test Set debe permanecer totalmente aislado.



4. K-fold preserva proporciones (Stratified).




5. Augmentation suma diversidad sin nuevos datos.



6. Reduce el Overfitting al aprender patrones generales.



7. Una transformación válida respeta el significado de la etiqueta.



8. Aplican solo a Train; Val/Test exigen estabilidad.


Hacia la Semana 9: El salto al Deep Learning

La nueva pregunta: Tenemos un dataset validado y diverso. ¿Cómo utilizamos estos datos para construir una solución con capacidad de representación masiva?

- Próximos pasos: Redes neuronales profundas, arquitecturas CNN, capas ocultas, y optimización.



Unidad 2: Preparación
(Problema + Dataset)



Unidad 3: Deep Learning