


Redes Neuronales Convolucionales (CNN)

Machine Learning 2026 | Semana 10

Arquitecturas profundas para el procesamiento y clasificación de datos con estructura espacial.




El problema estructural de las redes densas con imágenes

Convertir una imagen bidimensional en un vector plano (**Flatten** prematuro) destruye su **estructura intrínseca** y multiplica excesivamente los parámetros, elevando el costo computacional y el riesgo de **Overfitting**.

El desafío de los parámetros




La pérdida de la estructura espacial



Arquitectura dual: La línea de ensamblaje de una CNN

Una CNN se diseña específicamente para datos espaciales dividiendo su operación en dos grandes etapas.
La red transforma secuencialmente los píxeles brutos hasta predecir una clase final.



Objetivo: Transformar la imagen en representaciones jerárquicas útiles.

Componentes: Convolución, Activación (ReLU), Pooling.

Salida: Mapas de características.

Flatten o Global
Average Pooling


Objetivo: Utilizar los patrones extraídos para determinar la categoría.

Componentes: Capas Densas, Capa de Salida (Softmax).

Salida: Clase predicha (Probabilidades).

Convolución: Extrayendo patrones locales mediante Filtros

La convolución no conecta todos los píxeles; aplica una **pequeña matriz (Filtro o Kernel)** sobre diferentes regiones locales de la imagen.



El Filtro (Kernel):

Matriz pequeña (ej. 3×3). A diferencia de la visión tradicional, la red aprende los valores del filtro durante el Training mediante Backpropagation.


Parámetros Compartidos (Parameter Sharing):

El mismo filtro se desliza por toda la imagen. Si un filtro detecta un borde, funcionará sin importar si el borde está arriba, abajo o al centro. Reduce masivamente el número de pesos.


Configurando la Convolución: Stride, Padding y Activación ReLU

El comportamiento del filtro sobre el espacio de la imagen se controla mediante hiperparámetros geométricos, seguidos de una transformación matemática para filtrar la señal.

Stride (Paso)




Stride = 1: Desplazamiento lento, produce un mapa detallado.



Stride = 2: Saltos más amplios, reduce rápidamente la dimensión espacial.

Padding (Relleno)



valid: Sin relleno. La salida disminuye en tamaño.

same: Agrega un margen de ceros a la imagen original. Permite que el Feature Map mantenga las dimensiones de la entrada.

Activación ReLU



Aplicada tras la convolución.

$$f(x) = \max(0, x)$$

Filtro ReLU: apaga valores negativos.

Multiplicidad de Mapas y Reducción Espacial (Pooling)


Una capa no busca un solo patrón, busca docenas. Posteriormente, el sistema comprime la información más relevante para reducir costos y aportar tolerancia espacial.

Múltiples Filtros simultáneos



Una capa configurada con 32 filtros genera 32 Feature Maps diferentes (Ej. Filtro 1 = bordes, Filtro 2 = texturas).


Max Pooling



Analiza pequeñas regiones (ej. 2×2) y conserva exclusivamente el valor máximo. Disminuye drásticamente el tamaño espacial.

Aprendizaje Jerárquico: El Campo Receptivo

A medida que la imagen avanza por la red, el espacio físico disminuye, pero la cantidad de representaciones aumenta. El campo receptivo abarca regiones cada vez más amplias.

Profundidad de la Red	Campo Receptivo	Patrones Aprendidos	
Primeras Capas	Pequeño (Local)	Líneas, bordes, cambios de contraste, texturas simples.	
Capas Intermedias	Medio	Formas geométricas, combinaciones de bordes.	
Capas Finales	Global (Amplio)	Partes de objetos, estructuras complejas completas.	

De la arquitectura conceptual al código en Keras


En código Python, la estructura secuencial refleja exactamente el diseño de la línea de ensamblaje.

```
modelo = Sequential()

# Extractor (Azul)
modelo.add(Conv2D(32, (3,3), activation='relu',
input_shape=(224,224,3)))
modelo.add(MaxPooling2D((2,2)))
modelo.add(Conv2D(64, (3,3), activation='relu'))
modelo.add(MaxPooling2D((2,2)))

# Transición (Gris)
modelo.add(Flatten())

# Clasificador (Naranja)
modelo.add(Dense(128, activation='relu'))
modelo.add(Dense(4, activation='softmax'))
```




El puente de transición: Flatten vs. Global Average Pooling (GAP)

La conversión de tensores 3D a un formato apto para las capas densas de clasificación es una decisión de diseño crítica que impacta los parámetros y el sobreajuste.

Transition Comparison Matrix

Flatten




Transformación: Aplanamiento mecánico total. Destruye la estructura restante.

Ejemplo de Salida: $7 \times 7 \times 512 \rightarrow 25.088$ valores

Impacto: Alto costo en parámetros. Útil en diseños iniciales superficiales.

Global Average Pooling (GAP)




Transformación: Promedia cada Feature Map en un único valor escalar.

Ejemplo de Salida: $7 \times 7 \times 512 \rightarrow 512$ valores

Impacto: Altamente eficiente en memoria. Ideal para Transfer Learning.

Diseñando el Clasificador para el Proyecto Integrador


La última capa (Dense) debe coincidir matemáticamente con la naturaleza probabilística del Dataset.



Atención: Softmax entrega confianza matemática condicionada al entrenamiento, ¡un modelo puede estar muy confiado pero equivocado!

Estrategias de Regularización contra el Overfitting

Las CNN poseen una enorme capacidad para memorizar (ej. Train accuracy 99%, pero Validation accuracy 70%). Debemos integrar defensas en distintas etapas del flujo de datos.



1. Data Augmentation

Ubicación: Antes de las convoluciones.

Modifica imágenes dinámicamente. La red nunca ve exactamente la misma imagen dos veces.

2. Normalización

Ubicación: Inmediatamente al ingresar.

Escalar valores de entrada para estabilizar y acelerar el Training.

3. Dropout

Ubicación: Después de las capas densas.

Desactiva aleatoriamente unidades durante el entrenamiento, rompiendo codependencias.

Más allá del Accuracy: Diagnóstico y Matriz de Confusión

El Accuracy global puede camuflar problemas críticos. Analizar el comportamiento cruzado por clase es vital para mejorar el Dataset o la arquitectura.


Predicción \ Real	Plástico	Vidrio	Cartón	Metal
Plástico	90	2	6	2
Vidrio	3	85	2	10
Cartón	5	1	92	2
Metal	1	11	2	86

Insights Analíticos:

- **Problema detectado:** Vidrio y Metal se confunden mutuamente con alta frecuencia (10 y 11 errores cruzados).
- **Plan de acción:** Inspeccionar errores (¿Brillos similares? ¿Fondos oscuros?) y ajustar Data Augmentation o revisar etiquetado.

Iteración: El Flujo de Trabajo del Proyecto Integrador

El desarrollo de Deep Learning requiere un enfoque iterativo impulsado por el análisis de datos (Data-driven). La primera CNN rara vez es el modelo definitivo.



Decálogo: 10 Aprendizajes Clave sobre las CNN

Síntesis de los conceptos fundamentales para el diseño, entrenamiento y evaluación de modelos de procesamiento de imágenes.

 1. Aprovechan explícitamente la estructura espacial local de la imagen.

 2. La convolución utiliza filtros compartidos sobre toda la entrada.

 3. La red es *Data-driven*; los filtros se entrenan, no se programan.

 4. Cada filtro entrenado genera un Mapa de Características específico.

 5. El aprendizaje es jerárquico: de bordes simples a patrones abstractos.

 6. Pooling condensa el espacio, reduce parámetros y aporta tolerancia.

 7. Funcionan como Motor Dual: Extracción seguida de Clasificación.

 8. La Capa de Salida debe calibrarse exactamente al tipo de problema.

 9. El análisis por clase (Matriz de Confusión) es superior al *Accuracy* global.

 10. La CNN conforma el núcleo técnico del proyecto integrador.

Hacia la Semana 11: Del espacio a la secuencia

Hemos consolidado cómo procesar información donde la relación espacial importa. El siguiente paso evolutivo responde a la pregunta: ¿Qué ocurre cuando los datos poseen un orden histórico o temporal?

