


Redes para datos secuenciales: Arquitecturas LSTM

Semana 11 — Machine Learning 2026



En una secuencia, la posición y el contexto definen el significado


Datos Independientes

Edad: 25 | Ingreso: 800k

Edad: 37 | Ingreso: 1.2M

Cada observación puede analizarse de forma independiente.


Datos Secuenciales



El orden altera la información.


Intercambiar arbitrariamente los elementos puede destruir información relevante (aplica a texto, audio, series temporales y sensores).

Las redes tradicionales carecen de memoria para procesar secuencias




- Procesan cada entrada de manera aislada.
- No mantienen estado ni contexto previo.
- Incapaces de responder a la pregunta fundamental: ¿Qué ocurrió antes?

Las Redes Neuronales Recurrentes (RNN) incorporan un estado oculto



El desafío de las dependencias largas: Vanishing Gradient




- Cuando la secuencia es extensa, la red debe recordar información de muchos pasos atrás.
- Al aplicar Backpropagation a través de la secuencia, los gradientes se multiplican y pueden volverse extremadamente pequeños.
- Consecuencia: La red pierde la capacidad de aprender dependencias de largo plazo.

LSTM (Long Short-Term Memory) introduce una arquitectura de memoria dual

Vía Superior (Estado de Celda - C_t)

La vía directa mediante la cual la información relevante se mantiene a través de la secuencia.




Vía Inferior (Estado Oculto - h_t)

Procesamiento local y a corto plazo.

A diferencia de una RNN simple, una LSTM incorpora mecanismos explícitos (compuertas) para decidir qué información conservar, olvidar y utilizar.

Tres compuertas controlan el flujo de la memoria




- Estas compuertas no se programan manualmente con reglas.
- Las decisiones de conservar o descartar son aprendidas mediante la función de Loss y Backpropagation.

Preparación de datos secuenciales: El pipeline de texto



Arquitectura de clasificación binaria para texto (Keras)

Architecture Stack & Keras Code



```
from keras.models import Sequential
from keras.layers import Embedding, LSTM, Dense

model = Sequential([
    Embedding(input_dim, output_dim,
              input_length=seq_len), # Representación secuencial
    LSTM(64), # Mayor capacidad / Riesgo Overfitting
    Dense(1, activation='sigmoid') # Clasificación binaria final
])
```


Configuraciones Avanzadas



Return Sequences: Devolver toda la secuencia o solo el último estado.





LSTM Apiladas: Múltiples capas para mayor profundidad.



Bidirectional LSTM: Analizar secuencias de izquierda a derecha y viceversa para obtener contexto de ambos lados.


Series temporales y el riesgo de Data Leakage



- En problemas tabulares se pueden mezclar registros aleatoriamente antes de dividir el Dataset.
- En series temporales, el orden temporal no puede alterarse.
- Mezclar valores futuros en el conjunto de Training genera Data Leakage.

Estrategias contra el Overfitting en LSTMs

Diagnóstico visual



Herramientas de mitigación



Reducir el número de unidades internas de la capa.



Obtener más datos (o aplicar Data Augmentation temporal).



Implementar Early Stopping durante el entrenamiento.



Configurar Dropout (soportado nativamente dentro de la capa LSTM en Keras).


Decisión arquitectónica: CNN versus LSTM

Dimensión	CNN	LSTM
Foco Principal	Estructura espacial	Estructura secuencial
Dato Típico	Imagen (Píxeles)	Texto, Serie Temporal, Audio
Relación Importante	Vecindad espacial local	Orden en el tiempo
Proyecto Integrador	SÍ (Clasificación de imágenes)	No es el modelo central

CNN no es 'mejor' que LSTM, ni LSTM es 'más avanzada' que CNN.
La arquitectura debe responder a la naturaleza del dato y al objetivo del problema.


Combinaciones estructurales y limitaciones actuales

CNN + LSTM



Limitaciones y Evolución

- Entrenamiento menos paralelizable y potencialmente lento.
- Dificultades persistentes con secuencias extremadamente largas.
- Contexto actual: Muchas tareas de lenguaje hoy utilizan arquitecturas basadas en Transformers (mecanismos de atención), pero LSTM sigue siendo el paradigma fundacional para entender la recurrencia.



Síntesis: 9 aprendizajes sobre datos secuenciales

1 El orden en secuencias contiene información vital.

2 Redes tradicionales carecen de estado explícito.

3 RNNs incorporan estado oculto y recurrencia.

4 RNNs sufren con dependencias de largo plazo.

5 LSTM fue diseñada para gestionar secuencias extensas.

6 Compuertas (Forget/Input/Output) controlan la memoria.

7 Aplicaciones principales: texto y series temporales.

8 CNN (espacial) vs LSTM (secuencial).

9 La selección arquitectónica depende del tipo de dato.

El mapa de Deep Learning: Hacia la Semana 12



Expandiendo nuestra caja de herramientas arquitectónicas.