



Semana 12: Autoencoders y Redes Generativas Adversarias (GAN)




**Más allá de la clasificación: Reconstrucción
y Generación en Deep Learning**



Concepto Clave: Hasta ahora, el objetivo principal era la clasificación. Esta semana exploraremos modelos diseñados para aprender representaciones internas, detectar anomalías y crear datos completamente nuevos.

¿Qué es un Autoencoder? La Tarea de la Reconstrucción



Restricción Fundamental

Entrenar una red para que devuelva su propia entrada parece trivial, pero la red se ve obligada a pasar la información por un 'cuello de botella' de menor dimensión.

Extracción de Patrones

Al forzar esta compresión y eliminar la redundancia, el modelo extrae y conserva únicamente las características y patrones esenciales de los datos.


Arquitectura Interna: Compresión y Reconstrucción



784 (X_{train}) $\rightarrow$ 128 $\rightarrow$ 32 (Latent Space z) $\rightarrow$ 128 $\rightarrow$ 784 (Reconstrucción)


Mecanismo de Entrenamiento: Aprendizaje auto-supervisado. La diferencia entre la entrada original y la reconstruida genera la Loss de reconstrucción, que ajusta los pesos vía Backpropagation.

Aplicaciones Prácticas de los Autoencoders




Eliminación de Ruido (Denoising)

Imagen con ruido → Autoencoder → Imagen limpia. El modelo aprende a ignorar las alteraciones aleatorias y reconstruir solo la estructura válida.



Reducción de Dimensionalidad


150.000 valores → Encoder → 128 valores. Crea vectores densos para visualización, clustering o como entrada para otros modelos predictivos.




Detección de Anomalías

Entrenado solo con datos normales. Una pieza normal produce un error bajo. Una observación defectuosa genera un error de reconstrucción anómalamente alto.

¿Qué es una GAN? El Paradigma Adversarial



Arquitectura de Flujo de una GAN



El Ciclo de Entrenamiento Adversarial




Paso 1: Entrenar el Discriminador

- Alimenta al Discriminador con Ejemplos Reales (etiqueta: 1) y Sintéticos (etiqueta: 0).
- El Discriminador ajusta sus pesos para mejorar su capacidad de clasificación binaria.

Paso 2: Entrenar el Generador

- Flujo: Ruido $\rightarrow$ Generador $\rightarrow$ Imagen Falsa $\rightarrow$ Discriminador.
- Se exige intencionalmente que el Discriminador responda '1' (Real).
- El error propagado vía Backpropagation actualiza exclusivamente los pesos del Generador.

Retos y Limitaciones de los Modelos Generativos



Mode Collapse

El Generador aprende a producir un único subconjunto de subconjunto de imágenes de buena calidad, ignorando la diversidad real del Dataset.



Calidad vs. Diversidad

Inestabilidad arquitectónica. Es complejo mantener el equilibrio entre imágenes fotorrealistas idénticas y muestras muy variadas pero con artefactos.



Ética y Sesgos Heredados

El modelo hereda y amplifica ciegamente las limitaciones del Dataset. Conlleva riesgos inherentes de desinformación, sesgos y falsificación.

Data Augmentation vs. Generación GAN

Data Augmentation

Mecanismo: Transforma observaciones existentes.

Imagen Real



Aplica transformación matemática
(Rotación, Zoom, Flip)




Versión modificada
de la misma imagen



Redes GAN

Mecanismo: Genera nuevos ejemplos desde una distribución.

Ruido Aleatorio



Pasa por el modelo estadístico entrenado



Ejemplo sintético
totalmente nuevo



Mensaje Central: Una GAN no transforma lo existente; “sueña” nuevos datos basados en patrones matemáticos aprendidos.

Matriz de Arquitecturas Deep Learning

Arquitectura	Entrada Típica	Objetivo Principal	Ejemplo Práctico
CNN	Imagen	Clasificación / Análisis espacial	Clasificar tipos de residuos
LSTM	Secuencia	Modelar dependencias temporales	Analizar texto
Autoencoder	Datos / Imagen	Reconstruir / Aprender representación latente	Detectar anomalías en producción
GAN	Ruido (+ Datos Reales en Training)	Generar muestras	Crear imágenes sintéticas

Integración al Proyecto (Clasificador de Imágenes)

GAN (Aumento de Dataset)

Opcional: Generar imágenes adicionales de clases subrepresentadas.

Autoencoder (Filtro)

Opcional: Detectar imágenes anómalas antes de que entren al flujo.

CNN (Clasificación)

Núcleo Obligatorio. El producto final continúa siendo:
Imagen $\rightarrow$ CNN $\rightarrow$ Clase.

Aclaración Crítica: No es obligatorio incorporar una GAN completa al proyecto. Hacerlo aumenta masivamente la complejidad técnica, recursos y tiempo de entrenamiento. La CNN es el núcleo; las demás son complementos potenciales.

Criterios de Calidad para Datos Sintéticos

Regla de Oro: Los datos sintéticos también son datos que deben validarse exhaustivamente antes de usarse.



Realismo

¿Es la muestra visualmente coherente con los datos físicos del mundo real?



Diversidad

¿Evitamos el Mode Collapse asegurando variedad, o el modelo solo genera clones?



Consistencia de Clase

¿Representa fielmente los atributos únicos de la categoría a la que será asignada?



Ausencia de Artefactos

¿Está libre de distorsiones visuales inducidas artificialmente por la red?

Síntesis de la Semana 12

Autoencoders

- Aprenden representaciones forzando una compresión (Encoder → Latent Space → Decoder).
- Usos críticos: Reducción de dimensionalidad y detección de anomalías sin necesidad de etiquetas.

Redes GAN

- Competición adversarial dinámica (Generador vs. Discriminador).
- Capacidad de sintetizar datos totalmente nuevos.
- Arquitecturas inestables propensas al Mode Collapse y a heredar sesgos.

Selección de Modelos

- Deep Learning va más allá de clasificar.
- Ninguna arquitectura es universalmente superior.
- Se seleccionan evaluando rigurosamente la ecuación: Dato + Objetivo + Restricciones.

Próximos Pasos: Hacia la Semana 13

S9: Fundamentos
DL

S10: Clasificación
CNN

S11: Secuencias
LSTM

S12: Autoencoders
& GANs

S13: Transfer Learning y Fine-Tuning

Pregunta Ancla:

¿Es necesario entrenar siempre una CNN masiva completamente desde cero?

Próximo Tema: Utilizaremos arquitecturas previamente entrenadas por la industria tecnológica como punto de partida para resolver de manera eficiente nuestros propios problemas de clasificación.