



Semana 13: Transfer Learning y Fine-Tuning

Estrategias para reutilizar modelos de Deep Learning en problemas de clasificación con datos limitados.




Base: Conocimiento Congelado (Capas Estáticas)

Clasificador: Arquitectura Entrenable (Ajuste Fino)



Entrenar una CNN desde cero requiere descubrir patrones visuales básicos.
Si no hay datos suficientes, ¿podemos heredar ese conocimiento?

Transfer Learning: Reutilizar el conocimiento estructural



Regla de oro: No transferimos respuestas de clasificación, transferimos los pesos capaces de detectar características visuales universales.

Desmontando el modelo: Base vs. Clasificador



La base como extractor de características (Feature Extractor)

Congelar (Freeze)

Mantener los pesos de la **base intactos, sin actualizarlos** durante el Training.

Beneficios

Protege características universales, **reduce drásticamente el costo computacional**.

Base Congelada
~3,900,000 parámetros
No entrenables

Solo realizamos operaciones de gradiente sobre el diminuto segmento naranja, ahorrando semanas de cálculo.



Implementación de Transfer Learning en Keras

Carga pesos preentrenados del inmenso Dataset ImageNet.

Corta y elimina el clasificador original de 1000 clases.

```
base_model = MobileNetV2(weights='imagenet', include_top=False)
base_model.trainable = False

x = GlobalAveragePooling2D()(base_model.output)
output = Dense(4, activation='softmax')(x)
```



Congela la base convolucional. Protege el conocimiento previo.

Reduce los múltiples mapas de características a valores promedio.



Inserta el nuevo clasificador entrenable para nuestras 4 clases.

Matriz de Decisión: ¿Cuándo aplicar Transfer Learning?

Dimensión Crítica	Entrenamiento desde Cero	Transfer Learning
Pesos Iniciales	Aleatorios	Preentrenados
Requisito de Datos	Altos volúmenes	Funciona con pocos datos
Tiempo de Training	Muy Alto (Días/Semanas)	Generalmente Menor (Minutos/Horas)
Riesgo (Overfitting)	Muy alto con pocos datos	Drásticamente disminuido
Flexibilidad	Total (Diseño libre)	Limitada al modelo base



Ideal cuando:

Dominio visual similar a fotografías naturales + Datos y recursos limitados.



Precaución cuando:

Dominios extremadamente atípicos (ej. microscopía) donde las texturas base no coinciden.

El siguiente nivel: Fine-Tuning (Ajuste Fino)

Transfer Learning = Reutilizar (Base estática)

La base preentrenada se mantiene completamente congelada. Solo se entrena un nuevo clasificador.

Fine-Tuning = Reutilizar + Adaptar
(Descongelar y ajustar selectivamente)

La base se reutiliza pero se descongelan selectivamente capas específicas para adaptarse mejor a la nueva tarea.

Fase 1: Transfer Learning Inicial



Fase 2: Fine-Tuning



Las capas iniciales se mantienen congeladas porque detectan patrones invariables (bordes). Solo se descongelan las últimas capas de la base para adaptar estructuras visuales complejas específicas.

El riesgo del Catastrophic Forgetting




El Peligro

Descongelar todo el modelo desde el inicio destruirá rápidamente los pesos útiles preentrenados.

La Solución en 2 Pasos

Primero, estabilizar el nuevo clasificador.
Segundo, aplicar Fine-Tuning cuidadoso.



Buscamos realizar ajustes finos y sutiles, no cambios bruscos que sobrescriban el conocimiento previo.

Selección del Modelo Base: Arquitecturas y Trade-offs



ResNet

Innovación: Conexiones residuales (skip connections).

Ventaja: Permite redes extremadamente profundas sin perder gradiente.



MobileNet

Innovación: Arquitectura altamente eficiente y ligera.

Ventaja: Ideal para hardware limitado o Edge Computing.




EfficientNet

Innovación: Escalado compuesto sistemático.

Ventaja: Equilibrio óptimo entre profundidad, ancho de capa y resolución.

Regla de Oro: La selección no debe basarse solo en el mayor Accuracy de Internet. Evaluar tamaño del dataset, recursos computacionales y viabilidad en producción.

Mejores Prácticas: Complementos del Entrenamiento




Reutilizar una arquitectura preentrenada complementa, pero jamás reemplaza, el diseño metodológico de control de datos.


Evidencia para la selección: Más allá del Accuracy global

Un modelo con alto Accuracy puede fallar sistemáticamente en una clase.
Se exige analizar Precision, Recall, F1-Score y matrices de confusión.

Transfer Learning Inicial



Después del Fine-Tuning



El Fine-Tuning adaptó las capas profundas para distinguir las sutilezas de textura entre el vidrio transparente y el metal reflectante.


Caso de Aplicación: Clasificación Automática de Residuos

Contexto del Dataset

4.400 imágenes | 4 clases
(Plástico, Vidrio, Cartón, Metal)

Dataset Context

Validación de Accuracy



Executiva design

“

Seleccionamos MobileNetV2 con Fine-Tuning porque presentó el mejor desempeño general, disminuyó la confusión específica entre vidrio y metal, y mantuvo un tamaño ligero (14 MB) compatible con nuestra futura implementación.

”

Síntesis Estructural: Semana 13

1

Transferencia de Pesos: Se reutilizan los detectores visuales generados por grandes Datasets, no las clasificaciones.

2

Congelamiento (Freeze): Protege el conocimiento previo bloqueando la actualización de la base al inicio del Training.

3

El poder del Fine-Tuning: Descongela progresivamente las últimas capas con un learning rate diminuto para evitar olvido catastrófico.

4

Trade-offs Arquitectónicos: Seleccionar el modelo exige equilibrar Accuracy, peso en disco (MB) y exigencia de hardware.

5

Evaluación Profunda: La superioridad se demuestra resolviendo confusiones específicas entre clases y analizando matrices, no solo reportando Accuracy.

El mejor modelo académico $\neq$ El mejor modelo en producción

Con esta sesión finaliza la **Unidad 3: Deep Learning**. Contamos con un modelo entrenado. El nuevo paradigma: En el mundo real, los dispositivos son limitados.



¿Cómo hacemos que nuestro modelo sea suficientemente rápido y ligero para operar fuera del entorno de entrenamiento?