





Optimización de Modelos de Machine Learning

Cuantificación, Poda y Estrategias para Inferencia en Producción | Semana 15

El Cambio de Prioridades: Training vs. Inferencia

Entorno de Training



Días/Horas

- **Prioridad:** Aprender correctamente (Accuracy máximo)
- **Características:** Múltiples épocas, cálculo de gradientes, backpropagation
- **Restricciones:** Tiempo y poder de cómputo abundantes

Entorno de Producción



00:00:050

Milisegundos

- **Prioridad:** Ejecutar eficientemente (Inferencia rápida)
- **Flujo:** Nueva imagen → Modelo → Predicción
- **Restricciones:** Batería, costo cloud, memoria ultralimitada

El Arte del Trade-off (Compromiso)



Objetivo: Modificar la representación del modelo para mejorar su eficiencia operativa sin degradar excesivamente su capacidad predictiva.

Más allá del Accuracy: Nuevas Métricas de Eficiencia

Tamaño del Modelo (MB)



Espacio en disco requerido. Depende de la cantidad de parámetros y su representación numérica en bits.


Latencia (ms)



Tiempo necesario para procesar una sola entrada. Crítico en aplicaciones interactivas.


Imagen → [ 120ms] → Predicción

Throughput (img/sec)



Volumen total de entradas procesadas por unidad de tiempo (ej. Batch de 50 imágenes por segundo).

Consumo de Recursos



RAM, CPU o GPU utilizados durante la ejecución. Suele ser mayor al tamaño del archivo debido a activaciones y buffers.

Cuantificación: Reduciendo la Precisión Numérica

FP32 (Floating Point 32 bits)

1 parámetro = 4 bytes

10M parámetros = 40 MB

FP16 (Floating Point 16 bits)

1 parámetro = 2 bytes

10M parámetros = 20 MB



INT8 (Enteros 8 bits)

1 parámetro = 1 byte

10M parámetros = 10 MB

La cuantificación mapea valores continuos (decimales) hacia valores discretos (enteros), reduciendo drásticamente el tamaño y el costo computacional con una pérdida marginal de precisión.

Estrategias: Post-Training vs. Quantization Aware Training


Post-Training Quantization (PTQ)	 Modelo FP32 → Conversión → Modelo INT8	Rápido y de menor complejidad. Ideal como primera aproximación tras terminar el entrenamiento.
Quantization Aware Training (QAT)	 Entrenamiento simulando INT8 → Conversión final	El modelo aprende a tolerar la baja precisión. Minimiza la caída de <i>Accuracy</i> , pero exige reentrenamiento.

Conversión PTQ con TensorFlow Lite

```
converter = tf.lite.TFLiteConverter.from_keras_model(modelo_keras)
converter.optimizations = [tf.lite.Optimize.DEFAULT]
tflite_quant_model = converter.convert()
```


Pruning (Poda): Eliminando Conexiones Irrelevantes

Paso 1: Red Completa




Red con todas las conexiones y pesos iniciales.

Paso 2: Magnitude Pruning



Los pesos cercanos a cero aportan poco a la predicción y se convierten en 0.

Paso 3: Red Dispersa (Sparse)




Red resultante con solo conexiones esenciales.

Métrica Clave: Sparsity (Dispersión)

$$\frac{500.000 \text{ pesos eliminados}}{1.000.000 \text{ pesos totales}} = 50\% \text{ Sparsity}$$

Niveles de Poda: No Estructurada vs. Estructurada


Poda No Estructurada



1.2	0.5	0.8	1.2
0.5	3.8	1.2	0.2
1.2	0.8	1.4	0.4
0.5	1.2	0.8	0.5

- Se eliminan pesos individuales (ceros aleatorios).
- **Pro:** Alta flexibilidad algorítmica.
- **Contra:** Difícil de acelerar en hardware estándar.

Poda Estructurada



1.2		0.5	0.8
0.5		2.3	0.2
0.5		0.8	0.2

- Se eliminan bloques lógicos completos (ej. filtros enteros).
- **Pro:** Produce una arquitectura físicamente más pequeña.
- **Contra:** Decidir qué bloque eliminar es más complejo.

Síntesis Estratégica: ¿Menos bits o menos conexiones?



Fase	Accuracy	Tamaño	Latencia
Original	92.0%	120 MB	320 ms
Pruned	91.8%	95 MB	280 ms
Quantized (Acumulado)	91.1%	28 MB	110 ms

Nota: Se sacrifica un 0.9% de Accuracy a cambio de reducir el tamaño en casi un 80% y triplicar la velocidad de inferencia.

Metodología: Cómo evaluar la Optimización sin errores

1. Establecer la Baseline



Medir **Accuracy, Tamaño y Latencia** del **modelo original** antes de modificar cualquier **parámetro**.
Es el único punto de referencia válido.

2. Evitar la trampa del Warm-up




Descartar siempre la **primera ejecución**.
Medir la **latencia promedio** solo sobre un **sistema estabilizado**.

3. Contexto de Medición



Definir el **entorno real**.
Medir la **Inferencia Individual (1 imagen)** para **tiempo real**, o el **Throughput** de un **Batch (múltiples imágenes)** para **procesamiento masivo**.

El Entorno Dicta la Solución y el Diseño



Proyecto Integrador: Seleccionando con Evidencia

Trazabilidad y Versionado



- [✓] Carga en el entorno destino
- [✓] Acepta el mismo formato de imagen
- [✓] Conserva las etiquetas originales

Evidencia

“La versión cuantificada V3 fue seleccionada porque **redujo el tamaño en 72%** y **mejoró la latencia en 56%**, con una caída en Accuracy de solo **0.6 puntos**, logrando el equilibrio ideal para nuestro despliegue proyectado.”

Buenas y Malas Prácticas en Optimización

✗ Lo que debemos evitar

- [✗] Optimizar sin **medir** una **baseline original** previa.
- [✗] Reportar únicamente el tamaño del archivo en disco, ignorando **memoria RAM** y **latencia**.
- [✗] Aplicar **cuantificación** y **poda** simultáneamente sin aislar qué técnica generó el impacto.
- [✗] Sobrescribir el archivo del **modelo original**.

✓ Las Mejores Prácticas

- [✓] Medir múltiples **inferencias** descartando el pico inicial de estabilización (Warm-up).
- [✓] Tratar la **latencia** como parte crítica de la experiencia del usuario final (UX).
- [✓] Realizar una **verificación funcional** de las **predicciones** tras modificar el modelo.
- [✓] Documentar rigurosamente el impacto en **Tamaño, Velocidad y Accuracy**.

Síntesis de la Semana 14

Objetivo: Producción vs. Entrenamiento




El paso a **Producción** cambia el objetivo: dejamos de aprender (entrenamiento) para buscar clasificación eficiente.

Trade-off: Eficiencia vs. Precisión



La eficiencia exige un **Trade-off**: sacrificar micro-porcentajes de Accuracy para ganar ligereza y velocidad.

Cuantificación: Reducción Numérica




Cuantificación: Reduce la precisión numérica (FP32 → INT8), encogiéndose drásticamente la huella de memoria.

Pruning (Poda): Eliminar Conexiones




Pruning (Poda): Elimina conexiones irrelevantes creando matrices dispersas (Sparse), acelerando el cómputo.

Evaluación Rigurosa: Medir Impacto



Evaluación rigurosa: Ninguna optimización es válida sin establecer baselines, evitar warm-ups y probar la inferencia.

Hacia la Semana 15: De la Optimización a la Interoperabilidad



Próximo paso: Transformar nuestro modelo en un artefacto universalmente interoperable para cualquier motor de producción.